[ԲՈՒՀ-Ի ԱՆՎԱՆՈՒՄԸ]

[ՖԱԿՈՒԼՏԵՏ / ԱՄԲԻՈՆ]

«Ինտելեկտուալ մեթոդներ տրանսպորտային համակարգերի օպտիմալացման համար»

ԱՎԱՐՏԱԿԱՆ ԱՇԽԱՏԱՆՔ

Լուսացույցների կառավարման մեթոդների ուսումնասիրություն և PPO-ի կիրառմամբ գնահատում

Կատարող՝ [ԱՆՈՒՆ ԱԶԳԱՆՈՒՆ]

Ղեկավար՝ [ԳԻՏԱԿԱՆ ՂԵԿԱՎԱՐԻ ԱՆՈՒՆ ԱԶԳԱՆՈՒՆ]

[ՔԱՂԱՔ] – 2026

Բովանդակություն

Ներածություն **3**

1 Լուսացույցների կառավարման մեթոդների ակնարկ **6**
1.1 Լուսացույցների կառավարման խնդիրը և որակի չափանիշները 6
1.1.1 Խնդրի բնութագիրը 6
1.1.2 Որակի չափանիշները 6
1.2 Լուսացույցների կառավարման դասական մեթոդները 7
1.2.1 Ֆիքսված ցիկլով կառավարումը և Վեբսթերի մեթոդը . . 7
1.2.2 Actuated կառավարումը 9
1.2.3 Ադապտիվ համակարգեր՝ SCOOT և SCATS 9
1.2.4 Max-Pressure մեթոդը 10
1.2.5 Մեթոդների համեմատություն 10
1.3 Ամրապնդող ուսուցում 11
1.3.1 Մարկովյան որոշումների ընդունման պրոցես 11
1.3.2 Q-ուսուցում 12
1.3.3 Deep Q-Network (DQN) 12
1.3.4 Քաղաքականության գրադիենտ մեթոդներ և PPO 13
1.3.5 Եզրակացություն բաժնի վերաբերյալ 13
1.4 Ամրապնդող ուսուցումը լուսացույցների կառավարման խնդրում 14
1.4.1 Խնդրի ձևակերպումը որպես MDP 14
1.4.2 Մեկ խաչմերուկի կառավարում 14
1.4.3 Խաչմերուկների ցանցի կառավարում 15
1.4.4 Առանցքային աշխատանքների մանրամասն դիտարկում 15
1.4.5 Բաց հարցեր 16
1.5 Գործիքներ և սիմուլյացիա 16
1.5.1 Օգտագործվող գործիքները և փորձարարական հասկացությունները 17
1.6 Եզրակացություններ գլուխ 1-ի վերաբերյալ 17

2 Խնդրի ձևակերպում և փորձարարական մեթոդաբանություն **19**
2.1 Խնդրի ձևակերպումը 19
2.2 Ճանապարհային ցանցի և հոսքերի մոդելը 19
2.3 Բազմագործակալ MDP և ընդհանուր քաղաքականություն . . 20
2.3.1 Դիտարկում 21
2.3.2 Գործողություններ և ժամանակային քայլ 21
2.3.3 Պարգևի ֆունկցիա 22
2.4 Համեմատվող բազային մեթոդները 22

2.5 Փորձարարական կարգը և վերարտադրելիությունը 23
2.6 Որակի չափանիշները 24
2.7 Գլխի եզրակացություն 25

Ներածություն

«Տրանսպորտային համակարգերի օպտիմալացման ինտելեկտուալ մեթոդներ» թեմատիկ ուղղության շրջանակում քաղաքային շարժունակության աճը խաչմերուկների արդյունավետ կառավարումը դարձնում է ճանապարհային ցանցերի աշխատանքի կարևոր խնդիր: Ճանապարհների ընդլայնումը հաճախ պահանջում է մեծ ֆինանսական ներդրումներ և սահմանափակ է խիտ կառուցապատված քաղաքներում, մինչդեռ լուսացույցների կառավարման ռազմավարության փոփոխությունը կարող է կիրառվել առկա ենթակառուցվածքի վրա: Միաժամանակ, ոչ ճիշտ ընտրված փուլերի տևողությունները մեծացնում են հերթերը, սպասման ժամանակը և տրանսպորտային միջոցների անհավասար սպասարկումը:

Լուսացույցների ավանդական կառավարումը հիմնվում է նախապես հաշվարկված պլանների կամ դետեկտորային կանոնների վրա: Այսպիսի մեթոդները թափանցիկ են և կիրառելի, սակայն դժվարությամբ են հարմարվում հոսքերի արագ փոփոխություններին կամ փոխկապակցված խաչմերուկների ցանցում առաջացող իրավիճակներին: Ամրապնդող ուսուցումը հնարավորություն է տալիս կառավարման քաղաքականությունը ստանալ սիմուլյատորի հետ փոխազդեցությունից՝ առավելագույնի հասցնելով ընտրված պարգևը [1, 2]: Սակայն RL մեթոդի բարձր արդյունքը մեկ ցուցանիշով դեռ չի նշանակում, որ այն կառավարում է ցանցը լավ. օրինակ, միայն ցանցի ներսի սպասումը նվազեցնելիս մեքենաների հերթը կարող է տեղափոխվել ցանցի մուտք:

Աշխատանքի արդիականությունը պայմանավորված է երկու հանգամանքով: Առաջին, անհրաժեշտ է RL մեթոդները համեմատել ոչ միայն պարզ ֆիքսված ծրագրի, այլև ուժեղ դասական կանոնների՝ Վեբսթերի, actuated և Max-Pressure կառավարման հետ: Երկրորդ, կարևոր է ստուգել, թե արդյոք մեկ սցենարի կամ մի քանի սցենարների վրա ուսուցված քաղաքականությունը պահպանում է իր հատկությունները այլ ծանրաբեռնվածությունների և փոխկապակցված խաչմերուկների ցանցի դեպքում:

Աշխատանքի նպատակը SUMO սիմուլյատորում լուսացույցների կառավարման PPO քաղաքականության մշակումն ու գնահատումն է, դրա կիրառելիության սահմանների ուսումնասիրությունը և համեմատությունը դասական կառավարման մեթոդների հետ՝ տարբեր ծանրաբեռնվածությունների պայմաններում:

Հետազոտության օբյեկտը քաղաքային ճանապարհային ցանցում շարժվող տրանսպորտային հոսքերն են: **Հետազոտության առարկան** լուսացույցների փուլերի ընտրության մեթոդներն են՝ ներառյալ

ամրապնդող ուսուցման վրա հիմնված ընդհանուր քաղաքականությունը:

Նպատակին հասնելու համար դրված են հետևյալ խնդիրները.

1. ուսումնասիրել լուսացույցների կառավարման դասական, ադապտիվ և RL մեթոդները,
2. կառուցել և ուսումնասիրել SUMO միջավայրում մեկ խաչմերուկի փորձարարական մոդելը, ինչպես նաև սահմանել 2×2 ցանցի ընդլայնման մոդելային պահանջները,
3. ձևակերպել խաչմերուկների ցանցի ընդլայնման խնդիրը որպես բազմագործակալ MDP՝ ընդհանուր PPO քաղաքականությամբ,
4. ընտրել գործակալի դիտարկումը, գործողությունների բազմությունը և պարգևի ֆունկցիան,
5. իրականացնել և համեմատել fixed, Webster, actuated, Max-Pressure և PPO մեթոդները,
6. գնահատել մեթոդների աշխատանքը տարբեր ծանրաբեռնվածությունների, պատահականության seed-երի և ուսուցման ընթացքում չտեսնված սցենարների դեպքում,
7. վերլուծել պարգևի ընտրության ազդեցությունը ցանցի ներսի և մուտքի մոտ գոյացող հերթերի վրա:

Աշխատանքի ներդրումը փորձարարական մեթոդաբանության մշակումն ու կիրառումն է, որի շրջանակում PPO-ն համեմատվում է ուժեղ դասական բազային մեթոդների՝ Webster-ի, actuated և Max-Pressure կառավարման հետ: Գնահատման մեթոդաբանությունը ներառում է ոչ միայն ցանցի ներսում սպասման ժամանակը, այլև ընդհանուր հերթը՝ հաշվի առնելով կանգնած և ցանց մուտք գործել սպասող մեքենաները, ինչպես նաև ուսուցման ընթացքում չօգտագործված սցենարների վրա քաղաքականության աշխատանքի ստուգումը: Մի քանի ծանրաբեռնվածությունների խառնուրդով ուսուցումն ու ընդհանուր պարամետրերի կիրառումը դիտարկվում են որպես փորձարկվող նախագծային ընտրություններ, այլ ոչ թե ինքնին նոր գիտական արդյունք:

Աշխատանքի գործնական նշանակությունն այն է, որ առաջարկվող մեթոդաբանությունը կարող է կիրառվել OpenStreetMap-ից ներմուծված Երևանի ճանապարհային ցանցի հատվածի համար: SUMO-ն աջակցում է ինչպես իրական քարտեզների ներմուծմանը, այնպես էլ արտաքին ծրագրով լուսացույցների կառավարմանը TraCI-ի միջոցով [3, 4]:

Աշխատանքը նախատեսվում է կազմել ներածությունից, երեք գլուխներից, եզրակացությունից, գրականության ցանկից և

հավելվածներից: Առաջին գլուխը ներկայացնում է տեսական հիմքերը և գոյություն ունեցող մեթոդները: Երկրորդ գլխում նկարագրվում են մեկ խաչմերուկի մոդելը, PPO գործակալը և փորձարարական մեթոդաբանությունը, ինչպես նաև 2×2 ցանցի ընդլայնման նախագծային մոտեցումը: Երրորդ գլխում պետք է ներկայացվեն իրականացված փորձերի արդյունքները. 2×2 ցանցի արդյունքները կարող են ներառվել միայն դրա կառուցումից և փորձարկումից հետո:

1. Լուսացույցների կառավարման մեթոդների ակնարկ

1.1. Լուսացույցների կառավարման խնդիրը և որակի չափանիշները

1.1.1. Խնդրի բնութագիրը

Ուրբանիզացիան և ավտոմեքենաների թվի աճը մեծացնում են քաղաքային ճանապարհային ցանցերի ծանրաբեռնվածությունը: Գերբեռնված խաչմերուկները առաջացնում են ժամանակի կորուստներ, վառելիքի ավելորդ ծախս և վնասակար նյութերի արտանետումներ, ուստի լուսացույցների կառավարման արդյունավետության բարձրացումը ճանապարհային իրավիճակի բարելավման կարևոր միջոց է՝ առանց նոր ճանապարհային ենթակառուցվածքի կառուցման:

Խաչմերուկը քաղաքային ճանապարհային ցանցի այն հատվածն է, որտեղ հատվում են տարբեր ուղղություններով շարժվող տրանսպորտային հոսքերը: Խաչմերուկի թողունակությունը սահմանափակ է, քանի որ կանաչ լույս միաժամանակ կարող է ստանալ միայն չհակասող ուղղությունների խումբը: Լուսացույցի կառավարումը հանգում է հետևյալ հարցին՝ ո՞ր ուղղությանը և որքա՞ն ժամանակով տալ կանաչ լույս: Սխալ որոշումները հանգեցնում են հերթերի առաջացման և ճանապարհային ժամանակի աճի [5].

Լուսացույցի ցիկլի երկարության ընտրությունը պայմանավորված է երկու հակադիր գործոններով: Յուրաքանչյուր փուլի փոփոխության ժամանակ առաջանում է կորսված ժամանակ, որը կապված է դեղին լույսի և կանգնած մեքենաների արագացման հետ: Ցիկլը կարճացնելիս այդ կորուստների մասնաբաժինը մեծանում է, իսկ ցիկլը երկարացնելիս կարմիր լույսի ընթացքում կարող են կուտակվել երկար հերթեր: Հետևաբար, օպտիմալ ցիկլի երկարությունը կախված է հոսքի ինտենսիվությունից և կորսված ժամանակից [5].

1.1.2. Որակի չափանիշները

Կառավարման որակը գնահատելու համար գրականության մեջ կիրառվում են մի քանի չափանիշներ՝

- **սպասման ժամանակ (հապաղում)՝** ժամանակը, որի ընթացքում մեքենան կանգնած է եղել,
- **հերթի երկարություն** և կանգնած մեքենաների քանակ,

- **հոսքի միջին արագություն,**
- **թողունակություն՝** մեկ ժամվա ընթացքում խաչմերուկով անցած մեքենաների քանակ,
- **ճանապարհի ժամանակ**:

Այս չափանիշներից և ոչ մեկը առանձին չի բնութագրում կառավարման որակը ամբողջությամբ, քանի որ դրանք չափում են տարբեր երևույթներ: Օրինակ, սպասման ժամանակը կարող է փոքր լինել այն դեպքում, երբ մեքենաների մի մասը չի հասցնում մտնել ցանց և չի հաշվառվում: Այդ պատճառով աշխատանքում կիրառվում է չափանիշների համակարգ, որը ներառում է նաև ընդհանուր հերթը՝ կանգնած և ցանց մտնել սպասող մեքենաների գումարը:

1.2. Լուսացույցների կառավարման դասական մեթոդները

1.2.1. Ֆիքսված ցիկլով կառավարումը և Վեբսթերի մեթոդը

Ֆիքսված ցիկլով կառավարման դեպքում լուսացույցի փուլերի հաջորդականությունը և յուրաքանչյուր փուլի տևողությունը նախապես սահմանվում են և չեն փոխվում ժամանակի ընթացքում: Ցիկլը բաղկացած է կանաչ, դեղին և, անհրաժեշտության դեպքում, բոլոր ուղղությունների համար կարմիր լույսի ժամանակահատվածներից: Նկար 1.1-ում պատկերված են երկփուլ խաչմերուկի փուլերը: Այս մոտեցման առավելությունը պարզությունն է. աշխատանքի ընթացքում այն չի պահանջում իրական ժամանակի դետեկտորային տվյալներ և հեշտությամբ համակարգվում է հարևան խաչմերուկների հետ: Թերությունը հոսքի փոփոխություններին չհարմարվելն է. պարամետրերը հաշվարկվում են միջին ինտենսիվության համար [5].

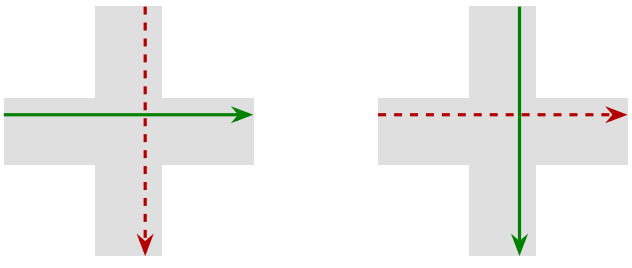


Рис. 1.1: Երկփուլ լուսացույցի փուլերը (կանաչ՝ շարժումը թույլատրվում է, կարմիր կետագիծ՝ արգելվում է)

Ցիկլի երկարության և փուլերի բաժանման դասական հաշվարկային մեթոդը ներկայացրել է Ֆ. Վեբսթերը [5]: Մեթոդում օգտագործվում են

հետևյալ մեծությունները: Յուրաքանչյուր փուլի համար որոշվում է հոսքի բեռնվածությունը

$$y_i = \frac{q_i}{s_i}, \tag{1.1}$$

որտեղ q_i-ն փուլի կրիտիկական ուղղության իրական հոսքն է, իսկ s_i-ն՝ հագեցման հոսքը, այսինքն՝ այն առավելագույն քանակի մեքենաները ժամում, որոնք կարող են անցնել խաչմերուկով՝ շարունակական կանաչ լույսի դեպքում: Խաչմերուկի ընդհանուր բեռնվածությունը

$$Y = \sum_i y_i. \tag{1.2}$$

Եթե $Y \geq 1$, խաչմերուկը գերբեռնված է ցիկլի ցանկացած երկարության դեպքում: Վեբսթերը ցույց է տվել, որ միջին հապաղումը նվազագույն է ցիկլի մոտավորապես հետևյալ երկարության դեպքում.

$$C_0 = \frac{1{,}5\,L + 5}{1 - Y}, \tag{1.3}$$

որտեղ L-ը ցիկլի ընթացքում կորսված ընդհանուր ժամանակն է: Արդյունավետ կանաչ ժամանակը բաժանվում է փուլերի միջև ըստ բեռնվածության.

$$g_i = (C_0 - L)\,\frac{y_i}{Y}. \tag{1.4}$$

Այսպիսով, ավելի բեռնված ուղղությունը ստանում է ավելի երկար կանաչ լույս: Մեթոդի սահմանափակումն այն է, որ այն օգտագործում է միջինացված հոսքեր և չի արձագանքում կարճաժամկետ տատանումներին:

Նկար 1.2-ը սխեմատիկորեն ցույց է տալիս մեթոդի հիմքում ընկած գաղափարը. ցիկլի երկարացմանը զուգընթաց կորուստների մասնաբաժինը նվազում է, իսկ հերթերի աճը՝ մեծանում, ուստի գումարային հապաղումն ունի նվազագույն:

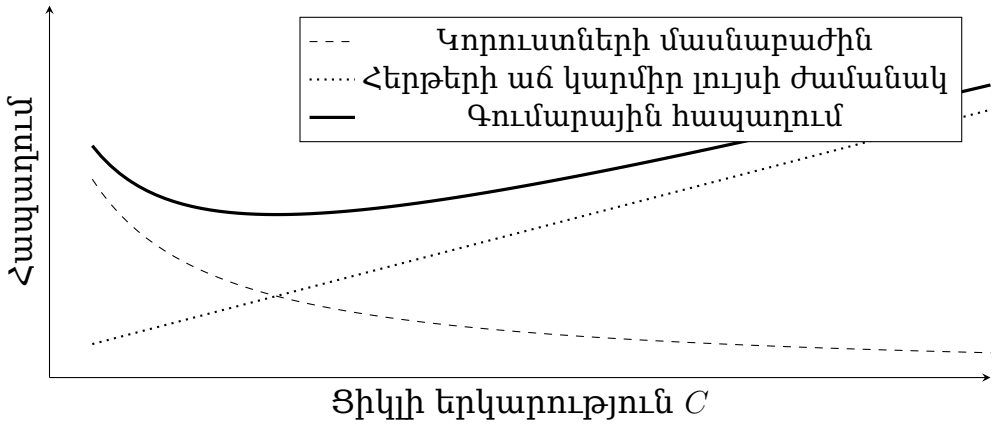


Рис. 1.2: Ցիկլի երկարության ազդեցությունը հապաղման վրա (սխեմատիկ)

Ցուցադրենք մեթոդը մեր փորձարկման խաչմերուկի օրինակով:

Արևմուտք-արևելք (WE) ուղղությամբ հոսքը կազմում է 0,5 մեքենա/վրկ (1800 մեքենա/ժ), հյուսիս-հարավ (NS) ուղղությամբ՝ 0,2 մեքենա/վրկ (720 մեքենա/ժ)։ Ընդունենք, որ հագեցման հոսքը յուրաքանչյուր ուղղության համար $s = 3600$ մեքենա/ժ (երկու գոտի)։ Այդ դեպքում $y_{\mathrm{WE}} = 0{,}5$, $y_{\mathrm{NS}} = 0{,}2$ և $Y = 0{,}7$։ Ենթադրելով, որ երկու փուլերի ընթացքում կորսված ընդհանուր ժամանակը $L = 8$ վրկ, ստանում ենք

$$C_0 = \frac{1{,}5 \cdot 8 + 5}{1 - 0{,}7} \approx 57 \text{ վրկ}, \qquad g_{\mathrm{WE}} \approx 35 \text{ վրկ}, \quad g_{\mathrm{NS}} \approx 14 \text{ վրկ}. \tag{1.5}$$

Համեմատության համար սույն աշխատանքի փորձերում օգտագործվող ֆիքսված ծրագիրը ունի երկու փուլ՝ յուրաքանչյուրը 42 վրկ կանաչով և 2 վրկ դեղինով (ցիկլը՝ 88 վրկ), այսինքն՝ ավելի երկար ցիկլ և հավասար բաժանում՝ չնայած հոսքերի 2,5 անգամ տարբերությանը։ Սա ցույց է տալիս, որ ֆիքսված կառավարման որակը մեծապես կախված է պարամետրերի ճիշտ ընտրությունից։

1.2.2. Actuated կառավարումը

Actuated (դետեկտորներով կառավարվող) համակարգերում խաչմերուկի մոտեցումների վրա տեղադրվում են դետեկտորներ, և փուլի տևողությունը որոշվում է մեքենաների ներկայությամբ։ Յուրաքանչյուր փուլի համար սահմանվում են նվազագույն և առավելագույն կանաչ տևողություններ։ Այս աշխատանքի SUMO մոդելում կիրառվում է gap-based actuated տրամաբանություն. նվազագույն ժամանակից հետո փուլը երկարացվում է, քանի դեռ գրանցվում է շարժում, և ավարտվում է սահմանված բացի կամ առավելագույն տևողության հասնելու դեպքում [6].

Այս մոտեցումը պարզ է, չի պահանջում հոսքի մոդել և աշխատում է տեղային տվյալներով։ Նրա թերություններն են՝ խաչմերուկների միջև համակարգման բացակայությունը և պարամետրերի (նվազագույն, առավելագույն տևողություններ, բացի շեմ) ձեռքով ընտրությունը։

1.2.3. Ադապտիվ համակարգեր՝ SCOOT և SCATS

Քաղաքային մասշտաբով կիրառվող ադապտիվ համակարգերը օգտագործում են դետեկտորների տվյալները իրական ժամանակում և փոփոխում են կառավարման պարամետրերը ըստ իրավիճակի։ Ամենահայտնի համակարգերն են SCOOT-ը և SCATS-ը։

SCOOT (Split, Cycle and Offset Optimisation Technique) համակարգը մշակվել է Մեծ Բրիտանիայում 1980-ականների սկզբին։ Այն օգտագործում է դետեկտորային տվյալների հիման վրա կառուցվող հոսքի մոդել և իրական ժամանակում ճշգրտում է երեք պարամետր՝ փուլերի բաժանումը (split), ցիկլի երկարությունը (cycle) և հարևան խաչմերուկների լույսերի հերթափոխման շեղումը (offset) [**hunt1981**].

SCATS (Sydney Coordinated Adaptive Traffic System) համակարգը մշակվել է Սիդնեյում: Այն ունի բաշխված, աստիճանային կառուցվածք. տեղային կարգավորիչները հարմարվում են տվյալ խաչմերուկի պահանջարկին, իսկ համակարգման մակարդակը կարգավորում է ցիկլը, փուլերի բաժանումը և շեղումները ցանցային մակարդակում [**lowrie1982**].

Այս համակարգերը ցույց են տալիս, որ ադապտիվ կառավարումը վաղուց կիրառվում է գործնականում: Սակայն դրանց ներդրումը պահանջում է դետեկտորային ենթակառուցվածք, ցանցի մանրամասն կարգաբերում և մասնագիտացված ծրագրային ու կազմակերպական աջակցություն:

1.2.4. Max-Pressure մեթոդը

Max-Pressure մեթոդի տեսական ձևակերպումներից մեկը ներկայացված է Պ. Վարայայի աշխատանքում [9]: Յուրաքանչյուր շարժման համար սահմանվում է ճնշումը՝ մուտքային գոտու հերթի և ելքային գոտու հերթի տարբերությունը: Փուլի ճնշումը այդ փուլի շարժումների ճնշումների գումարն է.

$$P(\varphi) = \sum_{(l,m)\in\varphi} \big(x_l - x_m\big), \tag{1.6}$$

որտեղ x_l-ը մուտքային գոտու, իսկ x_m-ը ելքային գոտու հերթն է: Յուրաքանչյուր պահի ընտրվում է առավելագույն ճնշմամբ փուլը:

Մեթոդի հիմնական առավելությունն այն է, որ որոշումը հիմնվում է միայն խաչմերուկին հարակից հերթերի վրա և կարող է ապակենտրոնացված իրականացվել: Վարայան ապացուցում է, որ համապատասխան մոդելի ենթադրությունների դեպքում Max-Pressure կառավարումը կայունացնում է հերթերը, եթե պահանջարկի վեկտորը գտնվում է ցանցի իրագործելի թողունակության շրջանի ներսում [9]: Մեկ մեկուսացված խաչմերուկի դեպքում, երբ ելքային գոտիները ազատ են, ճնշումը հանգում է մուտքային հերթերի համեմատությանը:

1.2.5. Մեթոդների համեմատություն

Աղյուսակ 1.1 ամփոփում է դիտարկված դասական մեթոդների հիմնական հատկությունները:

Դասական մեթոդները թափանցիկ են և կայուն, սակայն պահանջում են պարամետրերի ձեռքով կարգավորում և սահմանափակ ձևով են հաշվի առնում խաչմերուկների բարդ փոխազդեցությունը: Այս սահմանափակումներն են պատճառը, որ վերջին տարիներին լուսացույցների կառավարման համար ուսումնասիրվում են ամրապնդող

[1]Varaiya-ի մոդելի ենթադրությունների և իրագործելի պահանջարկի դեպքում [9]:

	Ֆիքսված (Վեբսթեր)	Actuated	SCOOT / SCATS	Max-Pressure
Դետեկտորներ	ոչ	այո	այո	այո
Հոսքի մոդել	միջին հոսքեր	ոչ	այո (SCOOT)	ոչ
Կառուցվածք	տեղային	տեղային	ցանցային, ապակենտրոնացված աստիճանային	
Հարմարվողականություն	ցածր	տեղային	ցանցային	տեղային
Տեսական երաշխիքներ	հաշվարկային	չկա	չկա	թողունակության օպտիմալություն[1]

Таблица 1.1: Դասական մեթոդների համեմատություն

ուսուցման մեթոդները:

1.3. Ամրապնդող ուսուցում

Ամրապնդող ուսուցումը (reinforcement learning, RL) մեքենայական ուսուցման ուղղություն է, որտեղ գործակալը սովորում է որոշումներ ընդունել՝ փոխազդելով միջավայրի հետ և ստանալով թվային պարգև: Ի տարբերություն վերահսկվող ուսուցման, ճիշտ պատասխանները նախապես տրված չեն. գործակալը պետք է ինքնուրույն գտնի այն գործողությունների հաջորդականությունը, որը առավելագույնի է հասցնում կուտակային պարգևը [1]: Լուսացույցների կառավարումը այս ձևակերպման բնական օրինակ է. որոշումները, թե որ փուլը միացնել, ազդում են ապագա հերթերի վրա, և լավ որոշման արդյունքը երևում է ոչ թե անմիջապես, այլ որոշ ժամանակ անց:

1.3.1. Մարկովյան որոշումների ընդունման պրոցես

Ամրապնդող ուսուցման խնդիրը ձևակերպվում է որպես Մարկովյան որոշումների ընդունման պրոցես (Markov decision process, MDP), որը սահմանվում է հնգյակով (S, A, P, r, γ): Այստեղ S-ը վիճակների բազմությունն է, A-ն՝ գործողությունների բազմությունը, $P(s' \mid s, a)$-ն՝ անցումների հավանականությունը, $r(s, a)$-ն՝ պարգևի ֆունկցիան, իսկ $\gamma \in [0, 1)$-ը՝ զեղչի գործակիցը: Յուրաքանչյուր t պահին գործակալը դիտարկում է վիճակը s_t, ընտրում է գործողություն a_t, ստանում է պարգև r_{t+1} և անցնում նոր վիճակի s_{t+1} (Նկար 1.3):

Գործակալի վարքագիծը նկարագրվում է քաղաքականությամբ $\pi(a \mid s)$՝ գործողությունների բաշխմամբ տվյալ վիճակում: Նպատակը զեղչված կուտակային պարգևի մաթեմատիկական սպասումի առավելագույնացումն է.

$$J(\pi) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k \, r_{k+1}\right]. \tag{1.7}$$

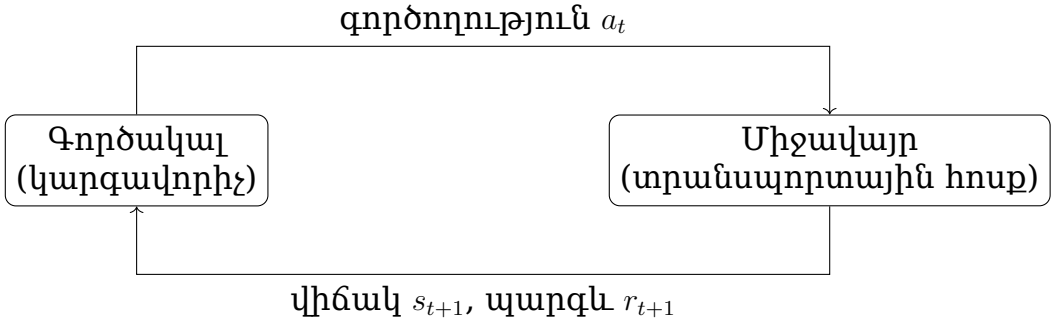


Рис. 1.3: Գործակալի և միջավայրի փոխազդեցությունը ամրապնդող ուսուցման մեջ

Քաղաքականության որակը բնութագրվում է արժեքի ֆունկցիաներով.

$$V^{\pi}(s) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \,\middle|\, s_t = s\right], \qquad Q^{\pi}(s,a) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \,\middle|\, s_t = s,\, a_t = a\right]. \tag{1.8}$$

Օպտիմալ գործողության արժեքի ֆունկցիան բավարարում է Բելմանի հավասարմանը.

$$Q^*(s,a) = \mathbb{E}\Big[\, r_{t+1} + \gamma \max_{a'} Q^*(s_{t+1}, a') \,\Big|\, s_t = s,\, a_t = a\Big]. \tag{1.9}$$

1.3.2. Q-ուսուցում

Q-ուսուցումը (Q-learning) մեթոդ է, որը գնահատում է Q^*-ը՝ թարմացնելով աղյուսակի արժեքները փորձի հիման վրա.

$$Q(s_t,a_t) \leftarrow Q(s_t,a_t) + \alpha\Big[\, r_{t+1} + \gamma \max_{a'} Q(s_{t+1},a') - Q(s_t,a_t)\Big], \tag{1.10}$$

որտեղ α-ն ուսուցման արագությունն է [10]: Մեթոդը աշխատում է ոչ միայն օպտիմալ, այլև ցանկացած քաղաքականության տվյալների հետ (off-policy): Նրա սահմանափակումն այն է, որ աղյուսակային ներկայացումը պահանջում է հնարավոր վիճակների ու գործողությունների թվարկում: Լուսացույցների խնդրում վիճակը ներառում է հերթերի երկարությունները, որոնք կարող են ընդունել բազմաթիվ արժեքներ, ուստի աղյուսակային մեթոդները կիրառելու համար անհրաժեշտ է դիսկրետացում, ինչը կորցնում է ճշգրտությունը:

1.3.3. Deep Q-Network (DQN)

Այս սահմանափակումը հաղթահարվում է արժեքի ֆունկցիան նեյրոնային ցանցով մոտարկելով՝ $Q(s,a;\theta)$: DQN մեթոդը [11] կայունացնում է ուսուցումը երկու մեխանիզմով: Առաջինը փորձի վերարտադրման բուֆերն է (experience replay). անցումները (s,a,r,s') պահվում են հիշողության մեջ և

ուսուցման ժամանակ ընտրվում են պատահականորեն, ինչը նվազեցնում է հաջորդական տվյալների կոռելյացիան։ Երկրորդը թիրախային ցանցն է (target network)՝ θ^{-} պարամետրերով, որը թարմացվում է ավելի հազվադեպ։ Կորստի ֆունկցիան է.

$$L(\theta) = \mathbb{E}\left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^{-}) - Q(s, a; \theta)\right)^2\right]. \tag{1.11}$$

DQN-ը ենթադրում է դիսկրետ գործողությունների բազմություն, ինչը համապատասխանում է լուսացույցի փուլի ընտրությանը։

1.3.4. Քաղաքականության գրադիենտ մեթոդներ և PPO

Արժեքի վրա հիմնված մեթոդներին այլընտրանք են քաղաքականության գրադիենտ մեթոդները, որոնք օպտիմալացնում են պարամետրացված քաղաքականությունը $\pi_\theta(a \mid s)$ անմիջապես։ Գրադիենտը գնահատվում է որպես

$$\nabla_\theta J(\theta) = \mathbb{E}\Big[\nabla_\theta \log \pi_\theta(a \mid s)\, \hat{A}(s, a)\Big], \tag{1.12}$$

որտեղ $\hat{A}(s, a)$-ն առավելության ֆունկցիայի գնահատականն է. այն ցույց է տալիս, թե ընտրված գործողությունը որքանով է ավելի լավ կամ վատ վիճակի միջին արժեքից։ Գործնականում օգտագործվում է actor-critic կառուցվածքը՝ մեկ ցանցը (actor) որոշում է քաղաքականությունը, մյուսը (critic) գնահատում է վիճակի արժեքը։

Proximal Policy Optimization (PPO) մեթոդը [2] կայունացնում է ուսուցումը՝ սահմանափակելով քաղաքականության փոփոխությունը մեկ թարմացման ընթացքում։ Նշանակենք $\rho_t(\theta) = \pi_\theta(a_t \mid s_t) / \pi_{\theta_{\text{old}}}(a_t \mid s_t)$։ Այդ դեպքում նպատակային ֆունկցիան է.

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t\Big[\min\Big(\rho_t(\theta)\hat{A}_t,\ \text{clip}\big(\rho_t(\theta),\, 1-\varepsilon,\, 1+\varepsilon\big)\hat{A}_t\Big)\Big], \tag{1.13}$$

որտեղ ε-ը կտրման պարամետրն է (գործնականում հաճախ $\varepsilon = 0{,}2$)։ PPO-ն համեմատաբար պարզ է իրականացնել, քիչ է զգայուն հիպերպարամետրերի նկատմամբ և լայնորեն կիրառվում է, այդ թվում՝ Stable-Baselines3 գրադարանում, որը օգտագործվում է սույն աշխատանքում։

1.3.5. Եզրակացություն բաժնի վերաբերյալ

Ամրապնդող ուսուցումը թույլ է տալիս կառավարման քաղաքականությունը ստանալ տվյալներից՝ առանց հոսքերի մաթեմատիկական մոդելի։ DQN-ը և PPO-ն հարմար են դիսկրետ գործողություններով խնդիրների համար։ Հաջորդ բաժնում դիտարկվում է, թե ինչպես են այս մեթոդները կիրառվել լուսացույցների կառավարման խնդրում։

1.4. Ամրապնդող ուսուցումը լուսացույցների կառավարման խնդրում

1.4.1. Խնդրի ձևակերպումը որպես MDP

Լուսացույցների կառավարման խնդիրը բնականորեն ձևակերպվում է որպես MDP: Գործակալը խաչմերուկի լուսացույցի կարգավորիչն է, միջավայրը՝ տրանսպորտային հոսքը: Մշակողի ընտրությունն է երեք բաղադրիչը՝ վիճակը, գործողությունը և պարգևը, և հենց այդ ընտրությունն է մեծապես որոշում արդյունքի որակը:

Վիճակ: Գրականության մեջ վիճակը նկարագրվում է տարբեր ձևերով՝ գոտիներում մեքենաների քանակ կամ խտություն, հերթերի երկարություններ, մեքենաների սպասման ժամանակ, ընթացիկ փուլ և դրա տևողություն: Առանձին աշխատանքներում օգտագործվում է նաև մեքենաների դիրքերի պատկերային ներկայացում [12]: Ավելի հարուստ վիճակը տալիս է ավելի շատ տեղեկություն, սակայն մեծացնում է ուսուցման բարդությունը:

Գործողություն: Սովորաբար գործակալն ընտրում է հաջորդ կանաչ փուլը նախապես սահմանված փուլերի բազմությունից, կամ որոշում է՝ շարունակել ընթացիկ փուլը, թե անցնել հաջորդին: Որոշումները կայացվում են ֆիքսված ժամանակային քայլով (օրինակ՝ մի քանի վայրկյան), իսկ փուլերի փոփոխության ժամանակ պարտադիր դեղին լույսը պահպանվում է:

Պարգև: Պարգևի ընտրությունը ամենազգայուն մասն է: Օգտագործվում են սպասման ժամանակի փոփոխությունը, հերթի երկարությունը, անցած մեքենաների քանակը, լույսերի փոխարկումների քանակի տուգանքը կամ դրանց կշռված գումարը [12, 13]: Եթե պարգևը չի համապատասխանում իրական նպատակին, գործակալը կարող է սովորել բարելավել միայն չափվող ցուցանիշը. օրինակ, եթե թե՛ պարգևը, թե՛ գնահատման չափանիշը հաշվի են առնում միայն ցանցի ներսի մեքենաները, ցանց չմտած մեքենաների հերթը մնում է աննկատ: Այս երևույթը դիտարկվում է գլուխ 3-ում:

1.4.2. Մեկ խաչմերուկի կառավարում

Առաջին աշխատանքներում կիրառվել են աղյուսակային մեթոդներ՝ հիմնականում Q-ուսուցումը պարզեցված վիճակի ներկայացմամբ [14, 15]: Խորը ուսուցման զարգացումից հետո կիրառվեցին DQN-ի տարբերակներ, որտեղ Q-ֆունկցիան մոտարկվում է նեյրոնային ցանցով [16, 17]: IntelliLight աշխատանքում առաջարկվել է DQN-ի վրա հիմնված մոտեցում, իսկ փորձարկումները կատարվել են տեսախցիկներից ստացված իրական տվյալների վրա [12].

1.4.3. Խաչմերուկների ցանցի կառավարում

Ցանցի դեպքում խնդիրը բարդանում է երկու պատճառով. առաջին՝ վիճակների և գործողությունների համատեղ տարածությունը աճում է ցանցի չափի հետ, երկրորդ՝ մեկ խաչմերուկի որոշումը ազդում է հարևանների մուտքային հոսքի վրա: Գոյություն ունեն երկու հիմնական մոտեցում:

Կենտրոնացված՝ մեկ գործակալ կառավարում է ամբողջ ցանցը: Մոտեցումը տեսականորեն ճշգրիտ է, սակայն գործողությունների տարածությունը աճում է էքսպոնենցիալ և մասշտաբավորվում է վատ:

Բազմագործակալ՝ յուրաքանչյուր խաչմերուկին համապատասխանում է առանձին գործակալ: Սա հանգեցնում է փոխազդեցության և ոչ ստացիոնար միջավայրի խնդրի, քանի որ մյուս գործակալների քաղաքականությունը փոխվում է ուսուցման ընթացքում: Լուծման եղանակներից են հարևանների դիտարկումների ավելացումը վիճակին, քաղաքականության պարամետրերի ընդհանուր օգտագործումը գործակալների միջև և հարևանների ազդեցության մոդելավորումը գրաֆային ուշադրության մեխանիզմով [**chu2020**, 19].

Այս ուղղության կարևոր աշխատանքներից է PressLight-ը, որտեղ պարգևը սահմանվում է Max-Pressure մեթոդի ճնշման հիման վրա, ինչը կապում է RL մոտեցումը դասական տեսության հետ [13].

Աղյուսակ 1.2 ամփոփում է դիտարկված աշխատանքների հիմնական ընտրությունները:

Աշխատանք	Վիճակ	Գործողություն	Պարգև
IntelliLight	հերթեր, սպասման ժամանակ, մեքենաների քանակ, փուլ, դիրքերի պատկեր	շարունակել կամ փոխել փուլը	մի քանի բաղադրիչի կշռված գումար
PressLight	փուլ, մեքենաների քանակ մուտքային և ելքային հատվածներում	փուլի ընտրություն	ճնշման բացասական արժեք
MA2C (Chu et al.)	տեղային և հարևանների դիտարկումներ	փուլի ընտրություն	հերթ և սպասում, տարածական զեղչով

Таблица 1.2: RL աշխատանքների համեմատություն

1.4.4. Առանցքային աշխատանքների մանրամասն դիտարկում

IntelliLight. Աշխատանքում [12] առաջարկվում է DQN-ի վրա հիմնված մոտեցում մեկ խաչմերուկի համար: Գործակալի վիճակը ներառում է հերթերի երկարությունները, մեքենաների քանակը, սպասման ժամանակը, ընթացիկ փուլը և մեքենաների դիրքերի պատկերային

ներկայացումը: Պարգևը կազմված է մի քանի բաղադրիչից՝ հերթ, սպասում, փուլերի փոփոխություններ և անցած մեքենաներ: Աշխատանքի առանձնահատկությունը փորձարկումն է տեսախցիկներից ստացված իրական տվյալների վրա:

PressLight. Այս աշխատանքում [13] պարգևը սահմանվում է Max-Pressure մեթոդի ճնշման հիման վրա: Հեղինակները ցույց են տալիս, որ այդ ընտրությունը կապում է RL մոտեցումը դասական կայունության տեսության հետ և կարող է նպաստել համակարգված կառավարմանը մայրուղու վրա՝ առանց այն նախապես նշելու: Սա օրինակ է այն բանի, թե ինչպես դասական տեսությունը կարող է ուղղորդել պարգևի ընտրությունը:

Multi-agent A2C (Chu et al.). Աշխատանքում [**chu2020**] խաչմերուկների մեծ ցանցի համար առաջարկվում է բազմագործակալ actor-critic մոտեցում: Մեթոդը կիրառում է տարածական զեղչ, որի դեպքում հեռավոր հարևանների պարգևները ավելի քիչ կշիռ ունեն, և գործակալներին տրվում է հարևանների քաղաքականության մասին լրացուցիչ տեղեկություն՝ ոչ ստացիոնարությունը նվազեցնելու համար: Փորձարկումները կատարվել են սինթետիկ ցանցի և Մոնակոյի իրական ճանապարհային ցանցի մոդելի վրա:

Այս աշխատանքներից յուրաքանչյուրը լուծում է խնդրի որոշակի մասը՝ վիճակի ներկայացումը, պարգևը կամ մասշտաբավորումը: Սույն աշխատանքում օգտագործվում է ավելի պարզ վիճակ և PPO՝ խաչմերուկների ցանցի համար ընդհանուր քաղաքականությամբ, իսկ գլխավոր շեշտը դրվում է ուժեղ բազային մեթոդների հետ ազնիվ համեմատության վրա:

1.4.5. Քաց հարցեր

Սույն աշխատանքի փորձարարական դիզայնում հատուկ ուշադրություն է դարձվում երեք հարցի: Նախ, PPO-ն համեմատվում է ոչ միայն ֆիքսված ծրագրի, այլև Վեբսթերի, actuated և Max-Pressure մեթոդների հետ: Երկրորդ, պարգևի և գնահատման չափանիշների համապատասխանությունը ստուգվում է՝ հաշվի առնելով ինչպես ցանցի ներսի, այնպես էլ մուտքի մոտ սպասող մեքենաները: Երրորդ, քաղաքականության ընդհանրացումը գնահատվում է ուսուցման ընթացքում չօգտագործված ծանրաբեռնվածությունների դեպքում:

1.5. Գործիքներ և սիմուլյացիա

Փորձերի համար օգտագործվում է SUMO (Simulation of Urban MObility) բաց կոդով միկրոսկոպիկ տրանսպորտային սիմուլյատորը [20]: Նրանում յուրաքանչյուր մեքենա մոդելավորվում է առանձին, իսկ լուսացույցների կառավարումը հասանելի է TraCI ծրագրային ինտերֆեյսով [4]: SUMO-

ն թույլ է տալիս ներմուծել իրական քարտեզներ OpenStreetMap-ից, ինչը հնարավորություն է տալիս ցանցային փորձերում օգտագործել Երևանի ճանապարհային ցանցի հատված [3, 21].

RL գործակալի և սիմուլյատորի կապի համար օգտագործվում է SUMO-RL գրադարանը, որն SUMO-ն ներկայացնում է Gymnasium միջավայրի ձևաչափով և աջակցում է մեկ ու մի քանի գործակալներով ուսուցում [22, 23]: Գործակալը իրականացվում է Stable-Baselines3 գրադարանում [24]՝ PPO ալգորիթմով: Բազային մեթոդները՝ ֆիքսված ցիկլը, actuated և Max-Pressure կառավարումը, իրականացվում են նույն միջավայրում՝ հավասար պայմաններում համեմատություն ապահովելու համար:

1.5.1. Օգտագործվող գործիքները և փորձարարական հասկացությունները

Աշխատանքում օգտագործվող հիմնական գործիքներն են SUMO-ն՝ քաղաքային երթևեկության միկրոսկոպիկ մոդելավորման համար, TraCI-ն՝ սիմուլյատորից տվյալներ ստանալու և լուսացույցները կառավարելու համար, SUMO-RL-ը՝ SUMO միջավայրը RL-ի համար հասանելի դարձնելու համար, Gymnasium-ը՝ միջավայրի ստանդարտ ինտերֆեյսի համար, և Stable-Baselines3-ը՝ PPO և այլ պատրաստի ալգորիթմների իրականացման համար: Ցանցային փորձերի համար նախատեսվում է OpenStreetMap-ից ներմուծել Երևանի փողոցների տվյալները SUMO միջավայր:

Փորձերի վերարտադրելիությունն ապահովելու համար կիրառվում է *seed*՝ պատահական հոսքի գեներատորի սկզբնական թիվը: Միևնույն seed-ը վերարտադրում է նույն պատահական սցենարը, իսկ մեթոդների արդյունքները գնահատվում են մի քանի տարբեր seed-երով: Համեմատվող մեթոդները կոչվում են *baseline*. տվյալ աշխատանքում դրանց շարքին են պատկանում ֆիքսված ցիկլը, actuated և Max-Pressure կառավարումը:

1.6. Եզրակացություններ գլուխ 1-ի վերաբերյալ

Գլխում դիտարկվել են լուսացույցների կառավարման դասական և ադապտիվ մեթոդները, ամրապնդող ուսուցման հիմունքները և դրա կիրառումը խնդրում: Դասական մեթոդները թափանցիկ են և կիրառելի, սակայն պահանջում են պարամետրերի ընտրություն և դետեկտորային ենթակառուցվածք: RL մեթոդները թույլ են տալիս քաղաքականությունը ստանալ տվյալներից, սակայն արդյունքը խիստ կախված է վիճակի, գործողության և պարգևի ընտրությունից: Այդ պատճառով աշխատանքի նպատակն է մշակել և գնահատել PPO-ի վրա հիմնված լուսացույցների կառավարման քաղաքականություն, ինչպես նաև ուսումնասիրել դրա կիրառելիության սահմանները՝ համեմատելով այն ուժեղ դասական մեթոդների հետ: Հաջորդ գլխում ձևակերպվում են խաչմերուկների ցանցի

կառավարման խնդիրը, PPO գործակալի վիճակը, գործողությունները և պարգևը, ինչպես նաև փորձարարական սցենարներն ու չափանիշները։

2. Խնդրի ձևակերպում և փորձարարական մեթոդաբանություն

Այս գլխում ձևակերպվում է խաչմերուկների ցանցի լուսացույցների կառավարման խնդիրը, նկարագրվում են SUMO մոդելը, ընդհանուր PPO քաղաքականությունը, բազային մեթոդները և գնահատման կարգը: Ներկայացված կոդային իրականացման փորձարարական հիմքը մեկ խաչմերուկի մոդելն է, որը թույլ է տալիս մեկուսացնել պարգևի և ծանրաբեռնվածության ազդեցությունը: 2×2 փոխկապակցված ցանցը դիտարկվում է որպես աշխատանքի հաջորդ ընդլայնման փուլ. դրա արդյունքները պետք է ներառվեն միայն ցանցային մոդելի իրականացումից և փորձարկումից հետո:

2.1. Խնդրի ձևակերպումը

Ընդհանուր ձևակերպմամբ դիտարկենք N լուսացույցով ճանապարհային ցանց: Յուրաքանչյուր $i \in \{1, \dots, N\}$ խաչմերուկի համար սահմանվում է միմյանց հակասող կանաչ փուլերի բազմություն Φ_i: Կառավարիչը յուրաքանչյուր որոշման պահին ընտրում է գործողություն $a_i \in \Phi_i$: Գործողությունը կարող է պահպանել ընթացիկ կանաչ փուլը կամ նախաձեռնել անցում դեպի հաջորդ թույլատրելի փուլը: Անվտանգության համար կանաչ փուլերի միջև SUMO-ն պարտադիր կերպով ներդնում է դեղին անցումային փուլ: Նշված բազմախաչմերուկ ձևակերպումը նկարագրում է նախատեսվող ցանցային ընդլայնումը. ընթացիկ փորձարկվող իրականացումը սահմանափակված է մեկ խաչմերուկով:

Կառավարման նպատակը միայն առանձին գոտում հերթի նվազեցումը չէ: Անհրաժեշտ է միաժամանակ նվազեցնել մեքենաների սպասման ժամանակը, ցանցի ներսում կուտակված հերթերը և ցանցի մուտքերում առաջացող մուտքային կուտակումը (այսուհետ՝ *backlog*)՝ պահպանելով բարձր թողունակություն: Այս նպատակները մասամբ հակասական են. օրինակ, որոշ ուղղության համար երկար կանաչը կարող է փոքրացնել ընթացիկ հերթը, սակայն մեծացնել մյուս ուղղությունների սպասումը: Ուստի մեթոդների համեմատությունը կատարվում է ցուցանիշների համակարգով, ոչ թե մեկ չափանիշով:

2.2. Ճանապարհային ցանցի և հոսքերի մոդելը

Սիմուլյացիոն միջավայրը կառուցվում է SUMO-ում: SUMO-ն միկրոսկոպիկ սիմուլյատոր է. այն առանձին է մոդելավորում յուրաքանչյուր մեքենայի շարժումը, արագությունը, գոտու ընտրությունը և լուսացույցի

ազդանշաններին արձագանքը [20]։ TraCI ինտերֆեյսը հնարավորություն է տալիս յուրաքանչյուր սիմուլյացիոն քայլում ստանալ գոտիների վիճակը և փոխել լուսացույցների փուլերը [4]։

Ընթացիկ փորձարարական իրականացման մեջ օգտագործվում է մեկ կարգավորվող խաչմերուկ՝ երկու հակասող կանաչ փուլերով. հյուսիս–հարավ և արևմուտք–արևելք ուղղությունների խմբերը սպասարկվում են հերթով։ Այս պարզ մոդելը հարմար է տարբեր պարգևների և բազային մեթոդների արդար համեմատության համար։ 2×2 խաչմերուկների ցանցը նախատեսված է որպես հաջորդ ընդլայնում, որտեղ մեկ խաչմերուկի ելքային հոսքը կդառնա հարևան խաչմերուկի մուտքային հոսք, և տեղային որոշումները կարող են առաջացնել կամ կանխել հերթերի տարածում ցանցում։

Ցանցի աշխարհագրական տվյալների աղբյուրը OpenStreetMap-ն է։ Քարտեզի ընտրված հատվածը ներմուծվում է SUMO-ի գործիքներով, որից հետո ճշգրտվում են խաչմերուկների երկրաչափությունը, գոտիները, լուսացույցային փուլերը և երթուղիները [3, 21]։ Այս մոտեցումը պահպանում է իրական ճանապարհային ցանցի կառուցվածքը, բայց թույլ է տալիս վերահսկել փորձի պայմանները։

Տրանսպորտային պահանջարկը նկարագրվում է երթուղիներով և մեքենաների մուտքի հավանականություններով։ Մեկ խաչմերուկի համար դիտարկվում են ցածր, միջին, բարձր և սիմետրիկ ծանրաբեռնվածություններ։ Բացի այդ, գնահատման մեջ ներառվում են ուսուցման ժամանակ չօգտագործված սցենարներ՝ միջին հոսքի 0.8 և 1.15 բազմապատիկները, ինչպես նաև ուղղությունների միջև անհավասարությունը փոխող հայելային սցենարը։ Ցանցի համար նույն սկզբունքով ստեղծվում են թեթև, միջին և բարձր հոսքերի սցենարներ։

2.3. Բազմագործակալ MDP և ընդհանուր քաղաքականություն

Նախագծվող ցանցային ընդլայնման դեպքում խաչմերուկների ցանցը կձևակերպվի որպես բազմագործակալ Մարկովյան որոշումների ընդունման պրոցես։ Յուրաքանչյուր լուսացույց կդիտարկվի որպես գործակալ, իսկ բոլոր գործակալները նախատեսվում է, որ կկիրառեն նույն նեյրոնային քաղաքականությունը π_θ՝ ընդհանուր պարամետրերով θ։ Այս մոտեցումը կոչվում է *parameter sharing* (պարամետրերի համատեղ օգտագործում)։ Այն կարող է նվազեցնել ուսուցվող պարամետրերի քանակը և հնարավորություն տալ նույն կանոնը կիրառել նմանատիպ խաչմերուկների վրա։ Այս ենթաբաժինը նկարագրում է նախագծային ձևակերպումը, ոչ թե արդեն ավարտված ցանցային իրականացումը։

Նախատեսվող ցանցային տարբերակում յուրաքանչյուր գործակալ i

որոշման պահին կդիտարկի իր տեղային վիճակը s_i և կընտրի գործողություն

$$a_i \sim \pi_\theta(a_i \mid s_i). \tag{2.1}$$

Նախատեսվող իրականացման մեջ բոլոր խաչմերուկների անցումները կմիավորվեն PPO ալգորիթմի ուսուցման համար, իսկ գնահատման ընթացքում գործակալը կընտրի քաղաքականության ամենահավանական գործողությունը: Ընդհանուր քաղաքականությունը չի ենթադրի, որ բոլոր խաչմերուկները պարտադիր կատարում են նույն գործողությունը. տարբեր տեղային վիճակների դեպքում կարող են ընտրվել տարբեր փուլեր: Այսպիսի բազմագործակալ միջավայրի ստանդարտ ինտերֆեյսը տրամադրում է SUMO-RL-ը [22].

2.3.1. Դիտարկում

Գործակալի դիտարկումը պետք է բավարար լինի տեղային որոշում ընդունելու համար և միաժամանակ չլինի չափազանց մեծ: Յուրաքանչյուր խաչմերուկի դիտարկումը կազմված է հետևյալ մասերից.

$$s_i = [p_i,\ m_i,\ d_{i,1}, \ldots, d_{i,L_i},\ q_{i,1}, \ldots, q_{i,L_i}], \tag{2.2}$$

որտեղ p_i-ն ընթացիկ կանաչ փուլի one-hot ներկայացումն է, m_i-ն ցույց է տալիս՝ արդյոք անցել է նվազագույն կանաչ ժամանակը, $d_{i,l}$-ը l գոտու խտությունն է, $q_{i,l}$-ը՝ այդ գոտու հերթի հարաբերական երկարությունը, իսկ L_i-ն մուտքային գոտիների քանակն է: Այս ներկայացումը համապատասխանում է SUMO-RL-ի լռելյայն դիտարկմանը [22]:

Ֆազայի և նվազագույն կանաչի մասին տեղեկությունը թույլ է տալիս քաղաքականությանը չփորձել անիրագործելի փոփոխություն, իսկ խտություններն ու հերթերը նկարագրում են տվյալ պահին պահանջարկի բաշխումը: Ցանցային մակարդակի ազդեցությունը քաղաքականությունը սովորում է հարևան խաչմերուկների ստեղծած տեղային հոսքերի միջոցով. հետագա տարբերակում դիտարկումը կարող է լրացվել հարևանների հերթերով կամ գրաֆային ուշադրության մեխանիզմով [19].

2.3.2. Գործողություններ և ժամանակային քայլ

Յուրաքանչյուր գործակալի գործողությունների բազմությունը բաղկացած է տվյալ խաչմերուկի թույլատրելի կանաչ փուլերից: Մեկ խաչմերուկի մոդելում առկա են երկու գործողություններ՝ հյուսիս–հարավ կամ արևմուտք–արևելք ուղղության համար կանաչ փուլը պահպանել կամ ընտրել: Որոշումները կայացվում են յուրաքանչյուր 5 վայրկյանը մեկ: Դեղին փուլի տևողությունը 2 վայրկյան է, իսկ կանաչ փուլի նվազագույն

տևողությունը 5 վայրկյան: Այդ սահմանափակումները կանխում են չափազանց հաճախակի փոփոխությունները և համապատասխանում են SUMO-RL միջավայրի ընդունված պարամետրերին [22].

2.3.3. Պարգևի ֆունկցիա

Սկզբնական տարբերակում օգտագործվում է SUMO-RL-ի լռելյայն `diff-waiting-time` պարգևը, որը խրախուսում է ցանցի ներսում կուտակված սպասման ժամանակի նվազեցումը: Սակայն միայն այս պարգևը կարող է բավարար չլինել բարձր ծանրաբեռնվածության դեպքում, քանի որ ցանց մուտք չգործած մեքենաները չեն մասնակցում ներսի սպասման հաշվարկին:

Ցանցային ընդլայնման համար որպես նախագծային տարբերակ դիտարկվում է նաև backlog-aware պարգևը

$$r_i = -\frac{Q_i^{\text{stop}} + B}{10}, \tag{2.3}$$

որտեղ Q_i^{stop}-ը i խաչմերուկին առնչվող կանգնած մեքենաների քանակն է, իսկ B-ն սիմուլյատորում ցանց մուտք գործել սպասող մեքենաների թիվն է: Նախատեսվող բազմագործակալ ցանցի դեպքում B-ն կլինի ընդհանուր և կարող է նպաստել նրան, որ տեղային գործակալները հաշվի առնեն ցանցի արտաքին սահմաններում գոյացող կուտակումը: Այս պարգևի ցանցային տարբերակը դեռ պետք է հաստատվի համապատասխան իրականացման և փորձերի միջոցով: Կշռիչ 10-ը չի փոխում օպտիմալ քաղաքականությունը, այլ միայն կարգավորում է պարգևի թվային մասշտաբը:

2.4. Համեմատվող բազային մեթոդները

PPO-ի արդյունքը գնահատվում է չորս բազային մոտեցումների համեմատ: Բոլոր մեթոդները գործարկվում են նույն ցանցի, երթուղիների, սիմուլյացիայի տևողության և պատահականության seed-երի պայմաններում: Այստեղ *baseline* տերմինը նշանակում է համեմատության համար ընտրված ելակետային մեթոդ:

- **Fixed** — նախապես սահմանված փուլերով և տևողություններով ֆիքսված ցիկլ: Այն ծառայում է որպես պարզ, ոչ ադապտիվ հենակետ:
- **Webster** — ֆիքսված ծրագիր, որի կանաչ ժամանակները հաշվարկվում են ըստ հոսքերի միջին ինտենսիվության և Վեբսթերի բանաձևի [5]: Փորձարարական իրականացման մեջ ընդունվում են հագեցման հոսք՝ 3600 մեքենա/ժ, կորսված ժամանակ՝ 8 վրկ, ցիկլի թույլատրելի միջակայք՝ 30–120 վրկ, և նվազագույն կանաչ՝ 7 վրկ:
- **Actuated** — դետեկտորային տվյալների վրա հիմնված gap-based կառավարում՝ նվազագույն կանաչ՝ 5 վրկ, իսկ առավելագույն կանաչը՝

ըստ փորձի կոնֆիգուրացիայի 30, 50 կամ 80 վրկ [6]։

- **Max-Pressure** — տվյալ պահին ամենամեծ ճնշմամբ փուլը ընտրող տեղային կանոն [9]։ Ներկայիս մեկ խաչմերուկի իրականացման մեջ համեմատվում են միայն մուտքային գոտիների հերթերը, քանի որ մեկուսացված խաչմերուկի համար ելքային գոտիների հերթերի տարբերությունը չի մոդելավորվում։ Ցանցային տարբերակում դասական Max-Pressure-ի ամբողջական հաշվարկը պետք է ներառի նաև ելքային գոտիների հերթերը։

Webster մեթոդը պահանջում է պահանջարկի միջին արժեքների իմացություն, actuated-ը՝ տեղային դետեկտորային ազդանշաններ, իսկ Max-Pressure-ը՝ հարակից գոտիների հերթերի չափումներ։ Այս տարբերությունը կարևոր է արդյունքների մեկնաբանման համար. RL-ի առավելությունը պետք է գնահատվի ոչ միայն որակի, այլև պահանջվող դիտարկումների տեսանկյունից։

2.5. Փորձարարական կարգը և վերարտադրելիությունը

Յուրաքանչյուր փորձարկման էպիզոդ տևում է 3600 վայրկյան, այսինքն՝ մեկ սիմուլյացիոն ժամ։ v4 գնահատման սկրիպտը PPO-ի յուրաքանչյուր տարբերակի համար նախատեսում է երեք ուսուցման seed-ով նախապես ուսուցված մոդելների ֆայլեր և լռելյայն օգտագործում է երեք գնահատման seed։ Սկրիպտն ինքնին մոդելները չի ուսուցանում, այլ բեռնում է արդեն պահպանված ֆայլերը։ Մոդելների իրական քանակը կախված է համապատասխան ֆայլերի առկայությունից. կոդը դրանց երեք լինելը պարտադիր կերպով չի ստուգում։ Seed-ը պատահական հոսքի գեներատորի կամ ուսուցման պատահական սկզբնավորման սկզբնական թիվն է. նույն պայմանների և seed-ի դեպքում փորձը հնարավոր է վերարտադրել։ Միջին արժեքն ու ստանդարտ շեղումը հաշվարկվում են ուսուցման և գնահատման seed-երի համակցություններով ստացված արդյունքների ամբողջության հիման վրա։

v4 գնահատման կոդում նախատեսված են PPO-ի երեք տարբերակներ՝ (1) մեկ միջին ծանրաբեռնվածության վրա ուսուցված քաղաքականություն (`ppo_single`), (2) ցածր, միջին, բարձր և սիմետրիկ ծանրաբեռնվածությունների խառնուրդի վրա ուսուցված քաղաքականություն (`ppo_mixed`), և (3) նույն խառնուրդի վրա backlog-aware պարգևով ուսուցված քաղաքականություն (`ppo_backlog`)։ Յուրաքանչյուր տարբերակի համար կոդը որոնում է երեք ուսուցման seed-երին համապատասխան մոդելային ֆայլեր։ Խառնուրդով ուսուցման դեպքում յուրաքանչյուր էպիզոդի սկզբում ընտրվում է հոսքի սցենար։ Այս համեմատությունը թույլ է տալիս ստուգել խառը

ծանրաբեռնվածությունների և պարգևի տարբերակների ազդեցությունը, սակայն ինքնին չի ենթադրում, որ խառնուրդով ուսուցումը պարտադիր ավելի լավ արդյունք կտա։

Մեկ խաչմերուկի իրականացված փորձերի գնահատումը բաժանվում է երկու խմբի. առաջին՝ ուսուցման ծանրաբեռնվածություններին համապատասխան սցենարներ, երկրորդ՝ չտեսնված միջանկյալ և հայելային սցենարներ։ 2×2 ցանցի հոսքերի գնահատումը նախատեսված է հաջորդ փուլում՝ ցանցի իրականացումից հետո։ PPO-ի գնահատման ժամանակ օգտագործվում է դետերմինիստական գործողության ընտրություն, որպեսզի արդյունքի պատահականությունը պայմանավորված լինի միայն սիմուլյացիոն պահանջարկով։

2.6. Որակի չափանիշները

Յուրաքանչյուր էպիզոդի համար հաշվարկվում են հետևյալ չափանիշները.

- **միջին սպասման ժամանակ մեկ մեքենայի համար** — ցանցի ներսում մեքենաների միջին հապաղումը,
- **կանգնած մեքենաների միջին քանակ** — ցանցի ներսի հերթի ցուցանիշ,
- **վերջնական հատվածի միջին հերթ** (`queue_final`) — վերջին 10 դիտարկման քայլերի ընթացքում ընդհանուր հերթի միջին արժեքը. եթե քայլի տևողությունը 5 վայրկյան է, ապա այն բնութագրում է ժամի վերջին մոտ 50 վայրկյանը, ոչ թե միայն վերջին ակնթարթը,
- **backlog** — էպիզոդի վերջում ցանց մուտք գործել սպասող մեքենաների թիվը,
- **ընդհանուր հերթ** — կանգնած և մուտք գործել սպասող մեքենաների թվերի գումարը,
- **թողունակություն** — մեկ ժամում երթուղին ավարտած մեքենաների քանակը,
- **միջին արագություն** — ցանցի ներսի շարժման հոսունության ցուցանիշ,
- **փուլերի փոփոխությունների թիվ** — կառավարման կայունության և չափազանց հաճախակի փոխարկումների ցուցանիշ։

Բազային մեթոդների համար միջինն ու ստանդարտ շեղումը հաշվարկվում են երեք գնահատման seed-երի արդյունքներով։ PPO-ի յուրաքանչյուր տարբերակի համար գնահատվում են ուսուցման

երեք seed-ով ստացված մոդելները՝ յուրաքանչյուրը երեք գնահատման seed-ով. հետևաբար յուրաքանչյուր սցենարի և PPO տարբերակի համար նախատեսված է մինչև $3 \times 3 = 9$ գնահատման դրվագ: Ամփոփ վիճակագրությունը հաշվարկվում է այդ դրվագների ամբողջությամբ: Բարձր ծանրաբեռնվածության դեպքում առաջնային ցուցանիշը ընդհանուր հերթն է, քանի որ միայն ցանցի ներսի սպասման ժամանակը կարող է թաքցնել մուտքերի մոտ առաջացած կուտակումը: Մեթոդը համարվում է ավելի կայուն, եթե այն պահպանում է փոքր ընդհանուր հերթ և բավարար թողունակություն ինչպես ուսուցման, այնպես էլ չտեսնված սցենարների դեպքում:

2.7. Գլխի եզրակացություն

Գլխում սահմանվել է փորձարարական մեթոդաբանությունը: Ներկայացվել է մեկ խաչմերուկի փորձարարական մոդելը և նկարագրվել է դրա ընդլայնման նախագծային ձևակերպումը՝ բազմագործակալ MDP-ի ու ընդհանուր PPO քաղաքականության միջոցով: Ներկայացվել են դիտարկումը, գործողությունները, պարգևի տարբերակները, բազային մեթոդները, ծանրաբեռնվածությունների սցենարները և գնահատման չափանիշները: Ցանցային իրականացումն ու դրա backlog-aware պարգևի փորձարկումը մնում են հետագա աշխատանքի խնդիր: Հաջորդ գլխում այս մեթոդաբանությամբ ստացված արդյունքները համեմատվում են և վերլուծվում:

Գրականության ցանկ

[1] Richard S. Sutton и Andrew G. Barto. *Reinforcement Learning: An Introduction*. 2-е изд. MIT Press, 2018.

[2] John Schulman и др. «Proximal Policy Optimization Algorithms». В: *arXiv preprint arXiv:1707.06347* (2017). URL: https://arxiv.org/abs/1707.06347.

[3] German Aerospace Center. *SUMO User Documentation*. URL: https://sumo.dlr.de/docs/ (дата обр. 24.10.2026).

[4] German Aerospace Center. *TraCI: Traffic Control Interface*. URL: https://sumo.dlr.de/docs/TraCI/ (дата обр. 24.10.2026).

[5] F. V. Webster. *Traffic Signal Settings*. Road Research Technical Paper 39. London: Her Majesty's Stationery Office, 1958.

[6] German Aerospace Center. *SUMO Traffic Lights Documentation*. URL: https://sumo.dlr.de/docs/Simulation/Traffic_Lights.html (дата обр. 24.10.2026).

[7] World Road Association (PIARC). *Urban Traffic Control*. URL: https://rno-its.piarc.org/en/its-basics-its-technologies-traffic-control/urban-traffic-control (дата обр. 24.10.2026).

[8] Transport for NSW. *Transport Modelling Guidelines: Signals and SCATS in Operational Modelling*. URL: https://standards.transport.nsw.gov.au/ (дата обр. 24.10.2026).

[9] Pravin Varaiya. «Max Pressure Control of a Network of Signalized Intersections». В: *Transportation Research Part C: Emerging Technologies* 36 (2013), с. 177—195. DOI: 10.1016/j.trc.2013.08.014.

[10] Christopher J. C. H. Watkins. «Learning from Delayed Rewards». Дис. ... док. King's College, University of Cambridge, 1989.

[11] Volodymyr Mnih и др. «Human-level Control through Deep Reinforcement Learning». В: *Nature* 518.7540 (2015), с. 529—533. DOI: 10.1038/nature14236.

[12] Hua Wei и др. «IntelliLight: A Reinforcement Learning Approach for Intelligent Traffic Light Control». В: *Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2018, с. 2496—2505. DOI: 10.1145/3219819.3220096.

[13] Hua Wei и др. «PressLight: Learning Max Pressure Control to Coordinate Traffic Signals in Arterial Network». В: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (2019). DOI: 10.1145/3292500.3330949.

[14] Marco Wiering. «Multi-Agent Reinforcement Learning for Traffic Light Control». В: *Proceedings of the 17th International Conference on Machine Learning*. 2000, с. 1151—1158.

[15] Baher Abdulhai, Rob Pringle и Grigoris J. Karakoulas. «Reinforcement Learning for True Adaptive Traffic Signal Control». В: *Journal of Transportation Engineering* 129.3 (2003), с. 278—285. DOI: 10.1061/(ASCE)0733-947X(2003)129:3(278).

[16] Wade Genders и Saiedeh Razavi. «Using a Deep Reinforcement Learning Agent for Traffic Signal Control». В: *arXiv preprint arXiv:1611.01142* (2016). URL: https://arxiv.org/abs/1611.01142.

[17] Elise van der Pol и Frans A. Oliehoek. «Coordinated Deep Reinforcement Learners for Traffic Light Control». В: *Proceedings of the Learning, Inference and Control of Multi-Agent Systems Workshop at NIPS*. 2016.

[18] Tianshu Chu и др. «Multi-Agent Deep Reinforcement Learning for Large-Scale Traffic Signal Control». В: *arXiv preprint arXiv:1903.04527* (2019). URL: https://arxiv.org/abs/1903.04527.

[19] Hua Wei и др. «CoLight: Learning Network-Level Cooperation for Traffic Signal Control». В: *Proceedings of the 28th ACM International Conference on Information and Knowledge Management* (2019). DOI: 10.1145/3357384.3357902.

[20] Pablo Alvarez Lopez и др. «Microscopic Traffic Simulation Using SUMO». В: *2018 21st International Conference on Intelligent Transportation Systems*. 2018, с. 2575—2582. DOI: 10.1109/ITSC.2018.8569938.

[21] OpenStreetMap Contributors. *OpenStreetMap*. URL: https://www.openstreetmap.org/ (дата обр. 24.10.2026).

[22] Lucas N. Alegre. *SUMO-RL: Reinforcement Learning Environments for Traffic Signal Control*. URL: https://github.com/LucasAlegre/sumo-rl (дата обр. 24.10.2026).

[23] Mark Towers и др. «Gymnasium: A Standard Interface for Reinforcement Learning Environments». В: *arXiv preprint arXiv:2407.17032* (2024). URL: https://arxiv.org/abs/2407.17032.

[24] Antonin Raffin и др. «Stable-Baselines3: Reliable Reinforcement Learning Implementations». В: *Journal of Machine Learning Research* 22.268 (2021), с. 1—8.